Diyabet Hastalarında 30 Günlük Yeniden Yatış Tahmini: Makalelerde Kullanılan Yöntemler

İncelediğimiz dokuz makalenin hepsinde ABD'deki 130 hastaneden toplanan, yaklaşık 101 bin yatışlık UCI Diabetes 130-US Hospitals veri seti kullanılmış. Amaç, taburcu olan bir hastanın 30 gün içinde tekrar hastaneye yatıp yatmayacağını önceden tahmin etmek. Hastaların sadece %11 kadarı geri yattığı için çoğu makale bu dengesiz dağılımla uğraşmış. Kaur ve arkadaşlarının makalesi biraz farklı: tahmin yapmak yerine gerçek veriye benzeyen yapay veri üretmişler.

1. Veri hazırlama

Makalelerin çoğu benzer adımlar izlemiş. Çok fazla eksik verisi olan sütunlar (kilo, ödeme kodu gibi) silinmiş. Az eksik olanlar ortalama, medyan ya da en sık görülen değerle doldurulmuş. Yazı olarak tutulan değişkenler sayıya çevrilmiş ve sayılar aynı aralığa getirilmiş. Bazı makaleler yeni özellikler de üretmiş, mesela hastanın önceki ziyaretlerinin toplamı ya da ilaç değişikliği sayısı.

2. Klasik makine öğrenmesi yöntemleri

Ağaç tabanlı modeller. Random Forest, birçok karar ağacı kurup hepsinin oylarına göre karar veriyor. XGBoost'ta ise ağaçlar sırayla kuruluyor ve her yeni ağaç, önceki ağaçların yaptığı hataları düzeltmeye çalışıyor. Emi-Johnson, Adegbosin, Albahli ve Boatemaa bu modelleri lojistik regresyon, SVM, KNN ve sinir ağlarıyla karşılaştırmış. Çoğunda ağaç tabanlı modeller en iyi sonucu vermiş.

Zeinalnezhad önce ki-kare testiyle en önemli 20 özelliği seçmiş. Sonra SVM'in C ve gamma ayarlarını genetik algoritmayla bulmuş. Bu makale veriyi dengelemek için yapay veri üretmemiş, her sınıftan 2500 gerçek kayıt seçmiş.

Emi-Johnson, SHAP yöntemini kullanmış. SHAP, her özelliğin bir hastanın riskini ne kadar artırdığını ya da azalttığını gösteriyor. Böylece modelin neden o kararı verdiği anlaşılabiliyor. Adegbosin ise sadece hiperglisemik kriz nedeniyle yatan hastalara bakmış ve riskli hastaları kaçırmamak için modeli duyarlılığa göre seçmiş. Ayrıca veriye gürültü ekleyip modelin bozulup bozulmadığını test etmiş.

3. Dengesiz veri ve karar eşiği

En çok kullanılan yöntem SMOTE. Az sayıdaki geri yatan hastaların birbirine yakın olanlarının arasında yeni yapay hastalar üretiyor. Adegbosin bunun üstüne ENN ile karışık örnekleri temizlemiş. Albahli rastgele örnek silme ve çoğaltma kullanmış, Emi-Johnson ise sınıflara farklı ağırlık vermiş. **Boatemaa'nın uyarısı önemli:** SMOTE çapraz doğrulamadan önce yapılırsa yapay örnekler hem eğitim hem test tarafına karışıyor ve sonuç gerçekte olduğundan çok daha iyi çıkıyor (AUROC 0,957 çıkmış, doğrusu 0,661). Bu yüzden SMOTE her katın içinde ayrı ayrı uygulanmalı. Aynı makale, 0,5 yerine Youden J istatistiğiyle seçilen bir karar eşiği kullanmış, çünkü 0,5 eşiğinde model geri yatışların neredeyse hiçbirini yakalayamıyor.

4. Derin öğrenme

Kategorik gömme (EmbPred30). Tanı kodu, ilaç gibi kategoriler tek tek 0-1 sütunlarına çevrilmek yerine kısa birer sayı listesine dönüştürülüyor ve bu listeleri model kendisi öğreniyor. Benzer kategorilerin listeleri birbirine yakın oluyor. Sonra bunlar sayısal özelliklerle birleştirilip iki gizli katmanlı bir sinir ağına veriliyor. Önce etiket kullanmadan, bozulmuş veriden asıl veriyi geri üretmeyi öğreten bir ağ eğitiliyor. Sonra bu ağın öğrendikleri asıl tahmin modeline aktarılıyor. Ama bu yöntem ağaç tabanlı modelleri geçememiş.

5. Zamana bakan, nedensel ve adil modeller

LSTM ve ağırlıklandırma. Hastanın yatışları tarih sırasına dizilip önceki yatışları hatırlayabilen LSTM modeline verilmiş. Önce DoWhy ile karıştırıcı faktörler hesaba katılmış, geriye kalan hata payları da örneklerin ağırlığı olarak kullanılmış. Yani modelin açıklayamadığı vakalara eğitimde daha çok önem verilmiş. Yazarlar bunun kesin bir nedensellik kanıtı olmadığını, sadece bir sezgisel yöntem olduğunu kendileri de yazmış. Sonuçta modelin ayırt etme gücü aynı kalmış ama olasılık tahminleri daha

güvenilir olmuş. Yaş grupları için ayrı eşik belirlemek de gruplar arası farkı azaltmış.

Difüzyon ve nedensel-değişmez temsil. Model tek bir ırk grubuyla eğitilip diğer gruplarda test edilmiş. Yöntemin iki parçası var. Birincisi difüzyon modeli: veriye adım adım gürültü eklenip sonra bunu geri almayı öğrenerek yeni örnekler üretiyor ve az temsil edilen grup için yapay kayıtlar oluşturuyor. İkincisi, modelin içindeki bilgiyi gruptan bağımsız sabit kısımlar ve gruba göre değişen kısımlar olarak ayırması. Gerçek ve yapay örneklerin temsilleri birbirinden çok uzaklaşırsa ceza veriliyor, böylece model gruba özgü kısayollara güvenmiyor.

6. Yapay sağlık verisi üretme (Kaur ve arkadaşları)

Bu makalede Bayes ağı kullanılmış. Bayes ağı, hangi değişkenin hangisine bağlı olduğunu gösteren oklu bir grafik. Bu grafik veriden öğreniliyor. Sonra her değişkenin olasılıkları hesaplanıp, kökten başlayarak değişkenler sırayla rastgele örnekleniyor ve gerçek hastası olmayan yapay kayıtlar elde ediliyor. Kalite için dağılım testleri ve ilişki kuralları kullanılmış. Bir de sinir ağına gerçek mi yapay mı diye tahmin ettirilmiş, doğruluk yaklaşık %50 çıkınca ayırt edilememiş sayılmış. Gizlilik için de bir saldırgan senaryosu denenmiş.

Genel sonuç

Makalelere bakınca karmaşık modellerin her zaman daha iyi çıkmadığını gördük. Sonuçları asıl etkileyen şey, verinin nasıl bölündüğü ve yapay verinin nerede üretildiği gibi değerlendirme ayrıntıları. Bu yüzden SMOTE'u sadece eğitim verisinde kullanmak, karar eşiğini ayrıca seçmek ve gruplar arası adaleti kontrol etmek önemli.